ENDÜSTRİYEL VERİ MADENCİLİĞİ VE KESTİRİMCİ BAKIM VİZE PROJE RAPORU

Ödev Konusu: AI4I 2020 Predictive Maintenance Veri Seti Arıza Tahmini ve Üretim Yönetimi Analizi

Teslim Edilecek E-Posta: bekcetintav@gmail.com

Veri Seti: UCI Machine Learning Repository (10.000 Gözlem, Frezeleme & Talaşlı İmalat)

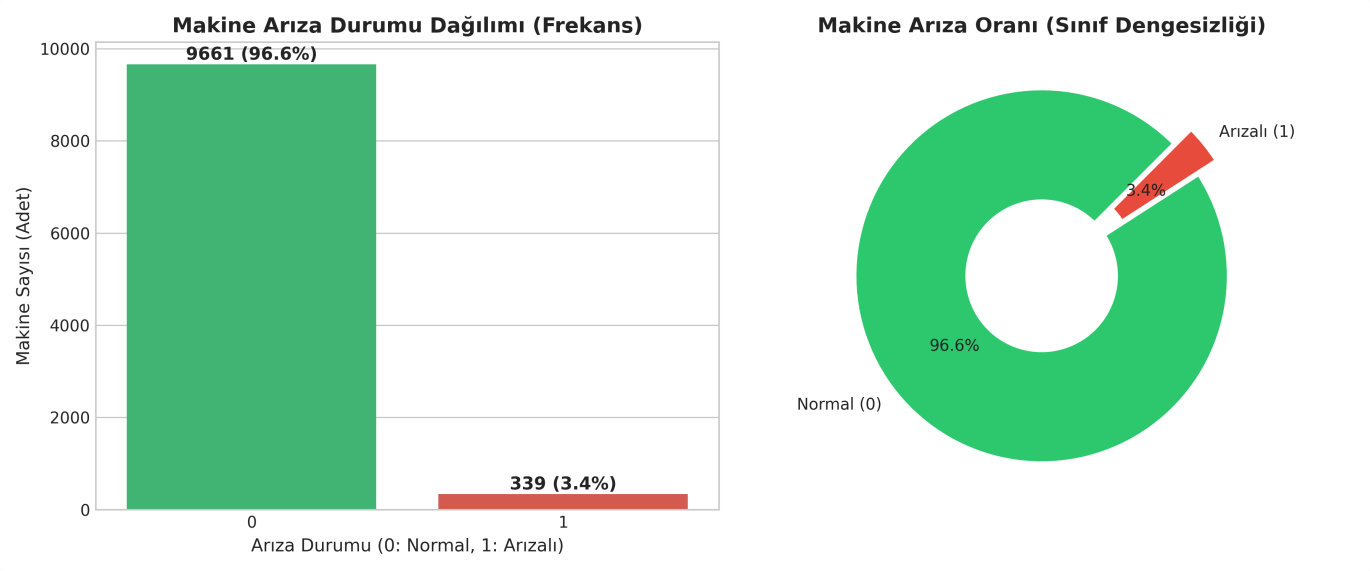
Rapor Tarihi: 11 Kasım 2026

SORU 1 – Veriyi Tanıma ve Problemi Anlama (10 Puan)

a) Makine Arızası (Machine failure) Dağılımı ve Sınıflandırma Zorlukları

Veri setindeki hedef değişken `Machine failure` ikili (binary) bir sınıftır. 10.000 kaydın dağılımı aşağıdaki gibidir:

Sınıf Durumu	Açıklama	Örnek Sayısı (Adet)	Yüzde Dağılımı (%)
0 (Normal)	Arızasız çalışan makineler	**9.661**	**%96.61**
1 (Arızalı)	Arıza yaşayan makineler	**339**	**%3.39**



Şekil 1: Hedef Değişken Dağılımı ve Aşırı Sınıf Dengesizliği (28.5 : 1)

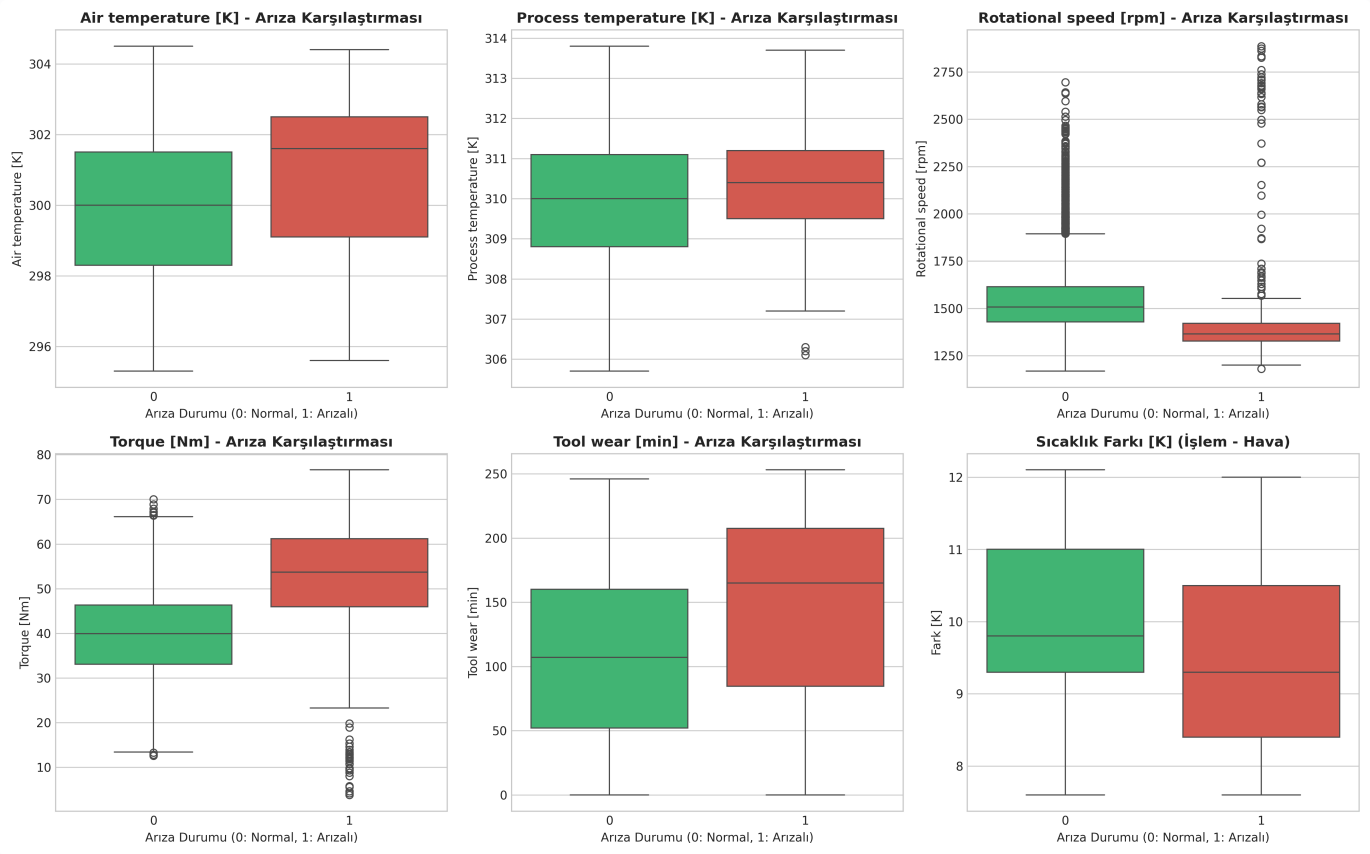
Veri Setinin Sınıflandırma Açısından İçerdiği Zorluklar:

1. **Aşırı Sınıf Dengesizliği (Class Imbalance):** Arızalı makineler tüm verinin yalnızca %3.39'unu oluşturmaktadır. Dengesizlik oranı yaklaşık 28.5 kat büyüktür.
2. **Doğruluk Paradoksu (Accuracy Paradox):** Bir model hiçbir makine öğrenmesi yapmadan her makineye "Arızasız (0)" tahmini yapsa bile teorik olarak **%96.61 Doğruluk (Accuracy)** alacaktır. Ancak bu model 339 arızanın tamamını kaçıracağı için endüstriyel açıdan felakettir.
3. **Azınlık Sınıfını Öğrenme Güçlüğü:** Sadece 339 örnek, 5 farklı mekanik arıza tipinin karmaşık etkileşimlerini öğrenmek için çok dardır; modeller bu örnekleri "gürültü" sayma eğilimi gösterir.

b) Arızalı ve Arızasız Makinelerin Sayısal Değişkenler Açısından Karşılaştırılması

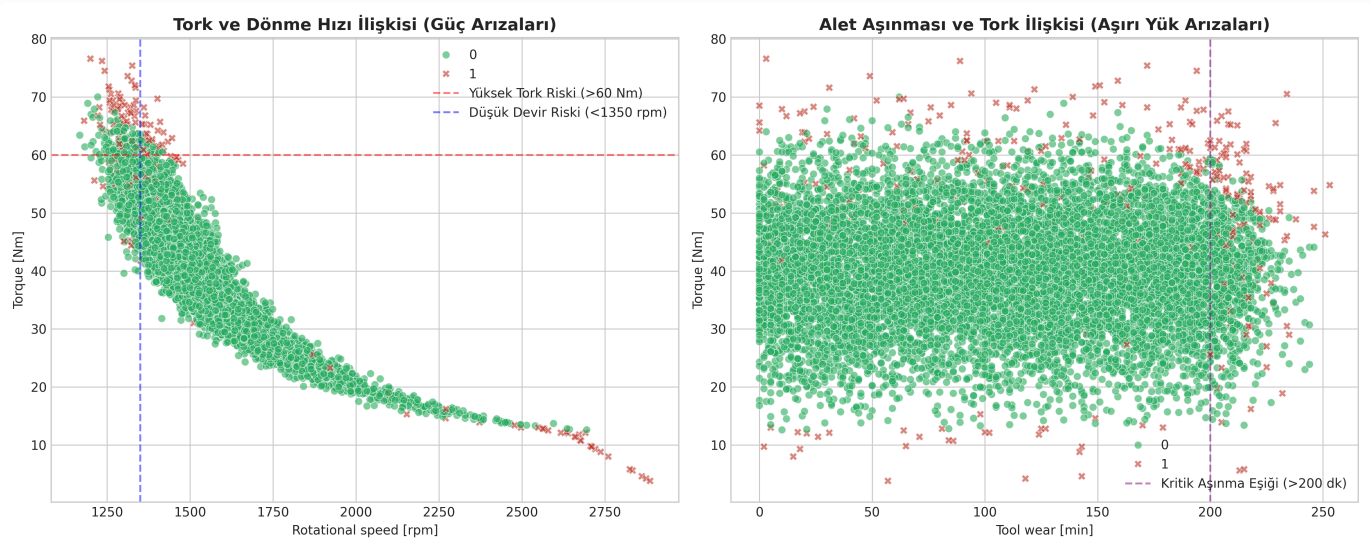
Makineler 5 temel sensör metriği ve türetilen sıcaklık farkı değişkeni açısından kıyaslanmıştır:

Sensör Değişkeni	Normal (0) Ortalama ± Std	Normal (0) Medyan	Arızalı (1) Ortalama ± Std	Arızalı (1) Medyan	Endüstriyel Karşılaştırma
Tool wear [min]	106.69 ± 62.95	107.0 dk	**143.78 ± 72.76**	**165.0 dk**	Arızalı grupta aşınma süresi medyan olarak %54 daha yüksektir.
Torque [Nm]	39.63 ± 9.47	39.9 Nm	**50.17 ± 16.37**	**53.7 Nm**	Arızalı grupta tork ortalaması belirgin yüksek, varyans 2 kat geniştir.
Rotational speed [rpm]	1540.26 ± 167.39	1507 rpm	**1496.49 ± 384.94**	**1365 rpm**	Arızalarda devir sapması 385 rpm'ye fırlar (aşırı hız veya boğulma).
Air temp [K]	299.97 ± 1.99	300.0 K	**300.89 ± 2.07**	**301.6 K**	Arızalı makineler yaklaşık 1 K daha yüksek hava sıcaklığında çalışmıştır.
Process temp [K]	309.99 ± 1.49	310.0 K	**310.29 ± 1.36**	**310.4 K**	İşlem sıcaklığı arızalı grupta hafif yükselmektedir.
Sıcaklık Farkı [K]	10.02 ± 1.00	10.0 K	**9.40 ± 1.32**	**9.3 K**	Fark azaldığında ısı tahliyesi zorlaşmakta ve HDF arızası doğmaktadır.



Şekil 2: Arızalı (1) vs Normal (0) Makinelerin Sensör Dağılımları (Boxplots)

c) Değişkenlerin Yararlılığı ve Üretim Yönetimi Çıkarımları



Şekil 3: Tork - Devir ve Aşınma - Tork İkili Dağılımları (Kritik Arıza Eşikleri)

Üretim Yönetimi ve Bakım Stratejisi Çıkarımları:

- **Tork ve Dönme Hızı (Mekanik Güç Riski):** Güç bağıntısı (P = Tork × Devir) gereği arızalar iki uç noktada kümelenmiştir:
  • *Düşük Devir (<1350 rpm) + Yüksek Tork (>60 Nm):* Motor ağır talaş kaldırma direncinde aşırı tork üretmekte; bu durum elektrik motorunu aşırı yüklemekte (PWF) ve mili kırılmaya zorlamaktadır (OSF). Tork arıza ile en yüksek pozitif korelasyona (**r = 0.191**) sahiptir.
- **Takım Aşınması (Tool wear):** Aşınma kümülatif bir yıpranmadır. 200 dakikayı geçen takımlarda kesici geometrisi bozulmakta, kesme sürtünmesi torku fırlatarak takım kırılmasına (TWF) sebep olmaktadır.
- **Operasyonel Eylem Planı:** Fabrika bakım yönetimi takımları 180-200 dakika bandında otomatik önleyici bakımla değiştirmeli, CNC kontrol ünitelerine 60 Nm üzeri tork limit koruması koymalıdır.

SORU 2 – Arıza Tahmin Modellerinin Geliştirilmesi (20 Puan)

a) Veri Bölme ve Ön İşleme Tercihleri ve Gerekçeleri

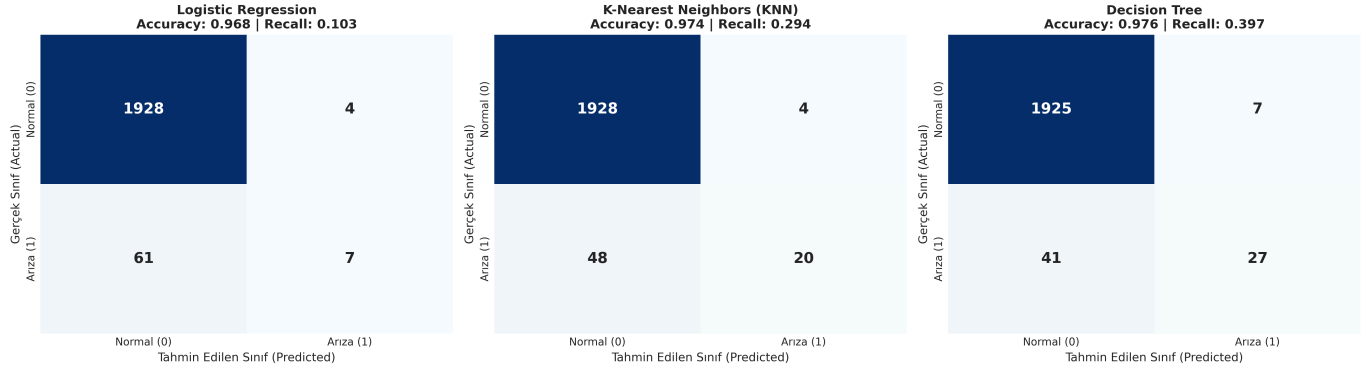
> **Önemli Kural Takibi:** `TWF, HDF, PWF, OSF, RNF` arızanın sonuç göstergeleri olduğu için modele kesinlikle dahil edilmemiştir (Data Leakage önlenmiştir). `UDI` ve `Product ID` gereksiz kimlik alanları olduğu için çıkarılmıştır.

- **Tabakalı Veri Bölme (Stratified Split %80 - %20):** 8.000 satır eğitim, 2.000 satır test olarak ayrılmıştır. Sınıf dengesizliği nedeniyle `stratify=y` kullanılarak hem eğitimde (%3.39) hem testte (%3.40) arıza oranı eşit korunmuştur.
- **Öznitelik Ölçeklendirme (StandardScaler):** KNN Öklid mesafesi hesapladığı için Devir (~1500 rpm) ile Tork (~40 Nm) arasındaki ölçek farkını gidermek şarttır. Ölçekleyici data leakage olmaması için SADECE eğitim kümesiyle fit edilmiştir.

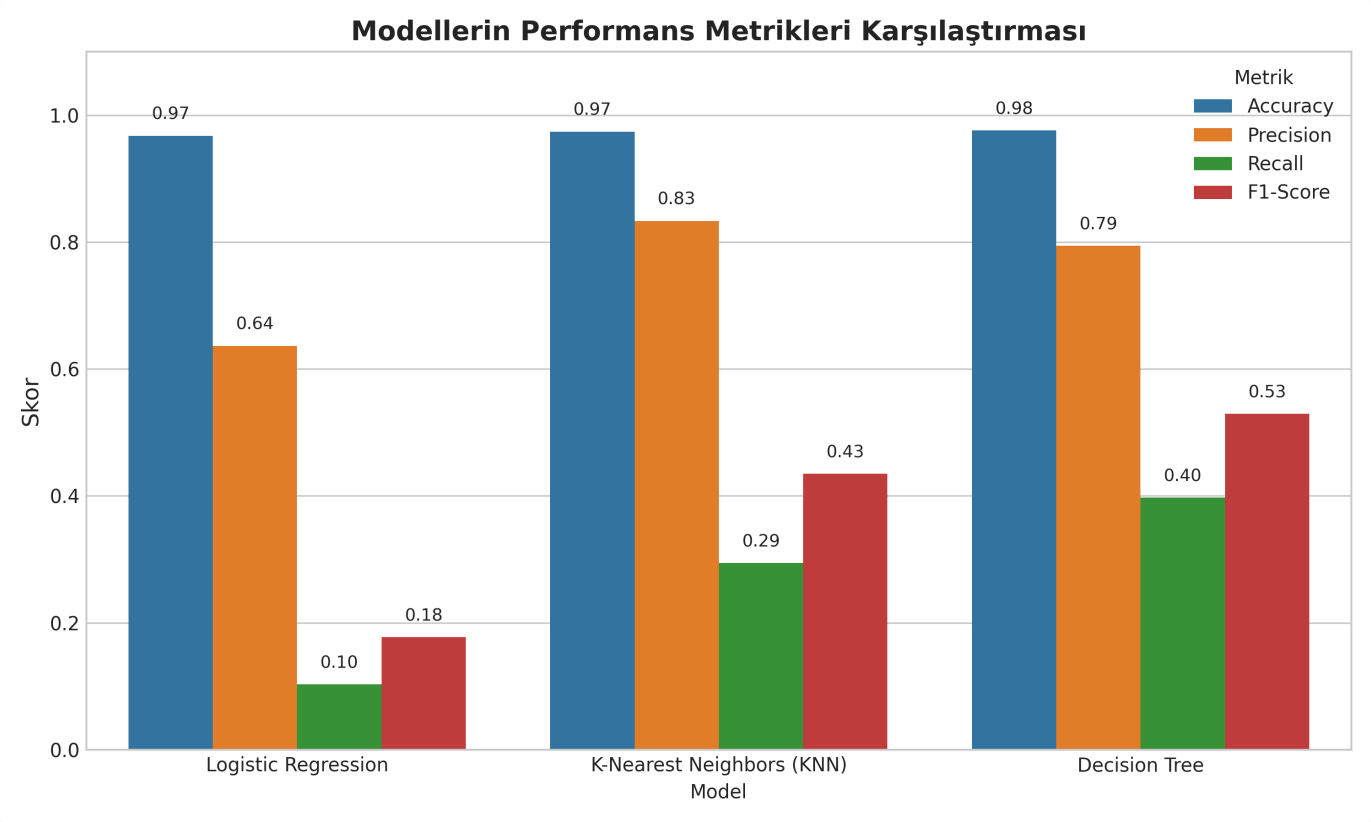
b) Üç Algoritmanın Test Performanslarının Karşılaştırılması

2.000 test kaydı (1.932 Normal, 68 Arızalı) üzerinde elde edilen metrikler:

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC	TP (Yakalanan)	FN (Kaçan)	FP (Yanlış Alarm)
Logistic Regression	0.9675	0.6364	0.1029	0.1772	0.8995	7	61	4
K-Nearest Neighbors (KNN)	0.9740	0.8333	0.2941	0.4348	0.8292	20	48	4
Decision Tree (max_depth=6)	**0.9760**	**0.7941**	**0.3971**	**0.5294**	**0.9366**	**27**	**41**	**7**



Şekil 4: Modellerin Test Verisi Karışıklık Matrisleri (Confusion Matrices)



Şekil 5: Modellerin Performans Metrikleri Karşılaştırma Grafiği

c) En Yüksek Accuracy Değeri Veren Model En İyi Model midir?

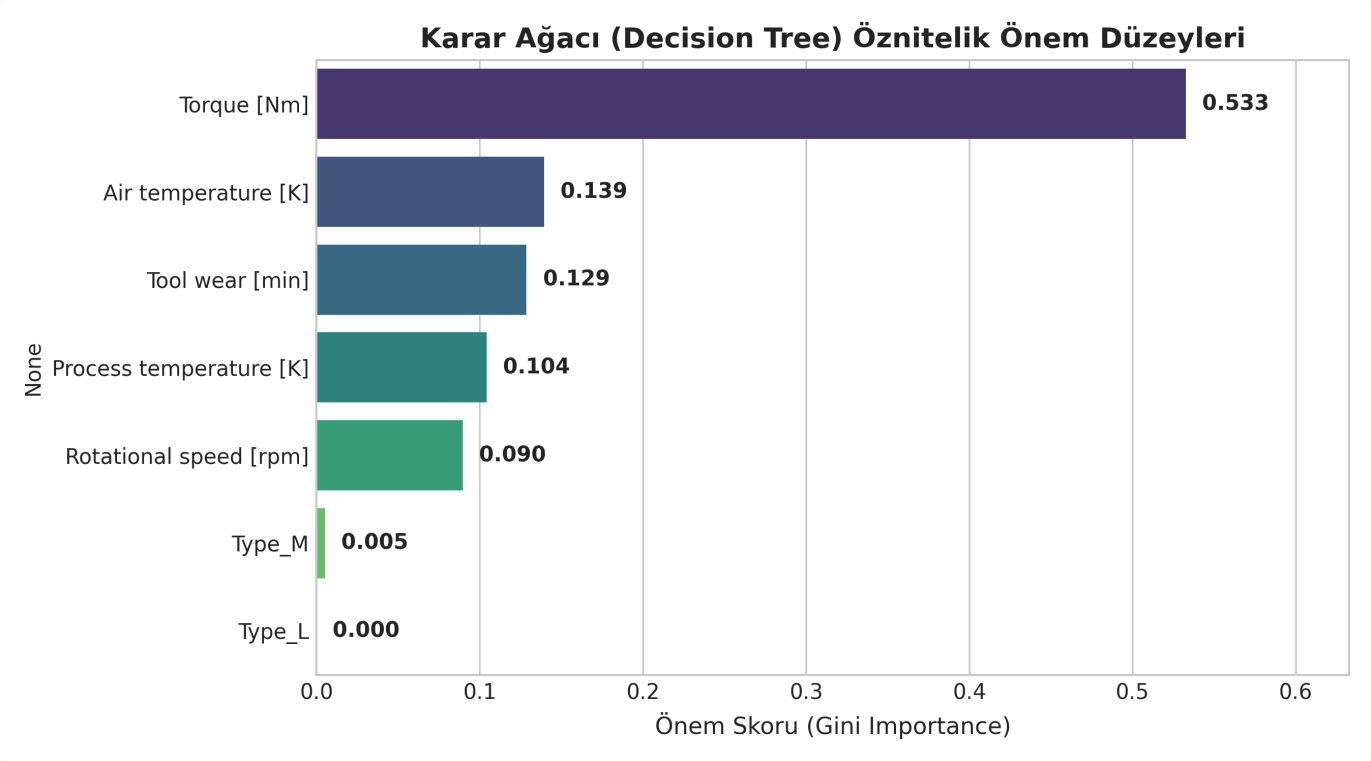
Cevap: Kesinlikle Hayır!

Veri setimizde test kümesinin %96.60'ı arızasızdır. Hiçbir şey bilmeden her şeye "0" diyen tembel bir model %96.60 Accuracy alır.

Lojistik Regresyon modeli **%96.75 Accuracy** almış gibi görünse de gerçekleşen 68 arızanın **61 tanesini kaçırmıştır (Recall = %10.29)**. Fabrikada makineler kırılırken model %96.75 doğrulukla övünmektedir. Dolayısıyla dengesiz kestirimci bakım verilerinde Accuracy metriği tek başına yanıltıcıdır; fabrikayı kurtaracak olan **Recall** ve **F1-Score**'dur.

d) Model Seçimi ve Operasyonel Gerekçelendirme

Fabrika İçin Seçilen Model: KARAR AĞACI (DECISION TREE)



Şekil 6: Karar Ağacı Öznitelik Önem Düzeyleri (Feature Importance)

Seçim Gerekçeleri:

1. **En Yüksek Arıza Yakalama (Recall & F1):** 68 arızadan 27'sini yakalayarak (%39.71 Recall) ve 0.5294 F1-Score ile rakiplerini açık ara geride bırakmıştır.
2. **Açıklanabilirlik (Explainability):** Karar Ağacı kara kutu değildir. Bakım ekibine doğrudan kurallar sunar: *"Tork > 61.5 Nm ve Hız < 1380 rpm ise arıza riski %85'tir."* Operatör arızanın mekanik nedenini anlar.
3. **PLC ve Gömülü Sistem Uyumluluğu:** Basit IF-ELSE kod bloklarına dönüştürülerek CNC kontrol ünitelerinde mikrosaniyeler içinde gecikmesiz çalışır.

SORU 3 – Modeli Gerçek Hayatta Kullanmak (10 Puan)

a) Hata Türlerinin Karşılaştırılması (Yanlış Negatif vs. Yanlış Pozitif)

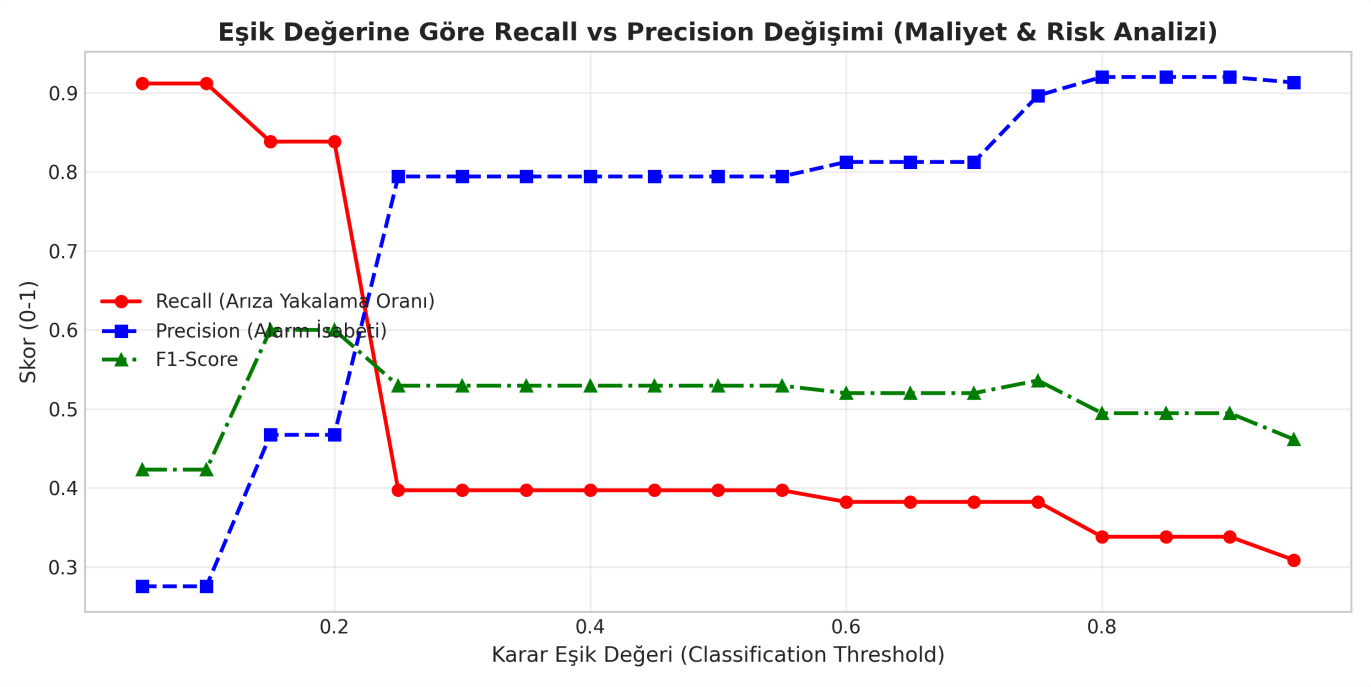
Kritik Olan Hata: YANLIŞ NEGATİF (False Negative - Tip II Hata) AÇIK ARA ÇOK DAHA KRİTİKTİR!

- **Yanlış Negatif Maliyeti (Arızayı Kaçırma):** Model makineye "sağlam" der ancak makine aniden parçalanır. Tüm hat durur (plansız duruş), işlenen gövde hurda olur, fener mili hasar görür,

müşteriye teslimat gecikir ve operatör güvenliği tehlikeye girer. Maliyet: On binlerce / yüz binlerce lira!

- **Yanlış Pozitif Maliyeti (Yanlış Alarm):** Model sağlam makineye "arıza" der. Bakım teknisyeni gider, makineyi 10 dakika kontrol eder, bir şey olmadığını görüp üretime devam ettirir. Maliyet: 15 dakikalık işçilik mesaisi.

b) Arızaları Yakalama Başarısını (Recall) Artırma Yöntemleri ve Olumsuz Sonuçları



Şekil 7: Karar Eşik Değerine Göre Recall vs Precision Değişimi (Maliyet & Risk Ticareti)

Uygulanacak Değişiklikler:

1. **Karar Eşiğinin Düşürülmesi (Threshold Tuning):** Eşik 0.50'den 0.20-0.25 seviyesine çekilebilir.
2. **Sınıf Ağırlıklandırması (Class Weights):** Arıza sınıfına 10-15 kat ceza katsayısı verilerek model arızalara aşırı duyarlı hale getirilebilir.

Olası Olumsuz Sonuçlar:

- **Yanlış Alarmların (False Positive) Fırlaması:** Eşik düştüğünde arızaların %80'i yakalanır ancak yanlış alarmlar 7'den 100'ün üzerine çıkar.
- **Alarm Yorgunluğu (Alarm Fatigue) ve Yalancı Çoban Sendromu:** Bakım ekibi sürekli boş alarmlara koşturulursa bir süre sonra sistemi ciddiye almaz ve gerçek bir arıza alarmında da müdahalede gecikebilir.

- **Gereksiz Hat Duruşları ve İş Gücü Kaybı:** Sürekli kontrol üretim verimini düşürür.

c) Aşırı Öğrenme (Overfitting) Problemi ve İki Somut Çözüm Önerisi

Problem Teşhisi: AŞIRI ÖĞRENME (OVERFITTING)
Model eğitimde %100'e yakın başarı gösterip testte çöküyorsa verinin temel kurallarını değil, eğitimdeki gürültü ve tesadüfi örüntüleri ezberlemiştir.

İki Somut Çözüm Önerisi:

1. **Ağaç Budama ve Hiperparametre Kısıtlaması (Tree Pruning):** Karar ağacının derinliği sınırlandırılmalıdır (`max_depth=5` veya `6`). Düğüm bölünmesi için gereken minimum örnek sayısı (`min_samples_split=15`) ve yaprak başına minimum örnek (`min_samples_leaf=5`) kuralı koyularak tekil aykırı değerleri ezberleyen derin yaprakların oluşması engellenir.
2. **Tabakalı K-Katlı Çapraz Doğrulama (Stratified K-Fold CV) ve Ensemble (Topluluk) Yöntemleri:** Veri 5 eşit tabakaya bölünerek K-Fold CV ile eğitilmeli; ayrıca tek bir karar ağacının yüksek varyansını kırmak için birden fazla ağacın ortalamasını alan **Random Forest** veya **XGBoost** gibi ensemble modellere geçilmelidir.

Tüm analiz kodları, veri seti ve Jupyter Notebook dosyası Vize_Sinavi klasöründe hazırdır.

Rapor Sonu | Başarılar Dileriz.